Phân vùng polyp đại tràng trên ảnh nội soi: so sánh mô hình CNN và Transformer, cải thiện khả năng tổng quát hóa trên dữ liệu ngoài miền

Nguyễn An Trần Điền và [Thành viên nhóm]

Trường Đại học Công nghệ Thông tin,
Thành phố Hồ Chí Minh, Việt Nam.

Tóm tắt

Mục đích: Các mô hình phân vùng polyp đạt Dice gần 0,90 trên ảnh của những trung tâm có trong dữ liệu huấn luyện, nhưng giảm mạnh trên ảnh từ trung tâm khác: PraNet đạt 0,898 trên Kvasir-SEG nhưng chỉ 0,628 trên ETIS. Phần lớn các so sánh đã công bố cũng chỉ dựa vào Dice. Nghiên cứu này so sánh các mô hình CNN và Transformer trên cùng một pipeline huấn luyện, và kiểm tra xem những thay đổi chi phí thấp có thu hẹp được khoảng cách ngoài miền hay không.
Phương pháp: Mọi mô hình được huấn luyện trên split PraNet của Kvasir-SEG và CVC-ClinicDB (1.450 ảnh) và kiểm tra trên năm bộ, trong đó ba bộ đến từ các trung tâm không xuất hiện khi huấn luyện. Nhóm tái hiện U-Net, MultiResUNet, CE-Net và TransUNet [và Swin-Unet] với cùng dữ liệu, augmentation, hàm mất mát và lịch huấn luyện, sau đó thêm hàm mất mát chú ý đường biên và augmentation theo màu sắc. Các mô hình được so sánh bằng Dice, IoU, recall và HD95; chênh lệch được kiểm định bằng phép kiểm định hạng có dấu Wilcoxon trên điểm của từng ảnh.
Kết quả: [Placeholder] Dice của từng mô hình trên tập trong miền và ngoài miền; độ lớn khoảng cách tổng quát hóa; Transformer có thắng CNN một cách có ý nghĩa thống kê hay không; tác dụng của từng cải tiến trong ablation; tốc độ suy luận.
Kết luận: [Placeholder] Một hoặc hai câu về phát hiện chính, kèm hạn chế chính (tập huấn luyện nhỏ, chỉ dùng benchmark công khai, ít lần chạy cho mỗi cấu hình).

Từ khóa: phân vùng polyp, nội soi đại tràng, U-Net, Vision Transformer, tổng quát hóa miền, boundary loss, kiểm định thống kê

1 Giới thiệu

Phần lớn ung thư đại trực tràng phát triển từ polyp trong đại tràng, và việc phát hiện, cắt bỏ polyp khi nội soi giúp giảm nguy cơ ung thư [trích dẫn]. Polyp khác nhau về kích thước, hình dạng và màu sắc, nhiều polyp trông gần giống niêm mạc xung quanh nên vẫn có thể bị bỏ sót. Phân vùng tự động khoanh vùng polyp đến từng điểm ảnh và có thể hỗ trợ bác sĩ trong lúc nội soi. Các mạng encoder–decoder dựa trên U-Net [1] là cách tiếp cận chuẩn, còn các mô hình gần đây mở rộng hoặc thay thế encoder tích chập bằng Transformer [2, 3].

Điểm số trên các benchmark quen thuộc rất cao, nhưng giảm mạnh trên dữ liệu từ trung tâm khác. PraNet đạt Dice trung bình 0,898 trên Kvasir-SEG và 0,899 trên CVC-ClinicDB, hai nguồn của dữ liệu huấn luyện, nhưng chỉ 0,709 trên CVC-ColonDB và 0,628 trên ETIS [4]. Cách đánh giá còn là vấn đề thứ hai. Một bài kiểm định 27 công trình phân vùng polyp cho thấy 26 bài không có kiểm định ý nghĩa thống kê, 25 bài bỏ qua HD95 và 25 bài bỏ qua recall; trên sáu trung tâm chưa thấy của PolypGen, mọi mô hình được đánh giá lại chỉ còn Dice 0,71–0,76 [5]. Vì vậy, chênh lệch Dice nhỏ đo trên tập trong miền không cho biết nhiều về việc mô hình nào hoạt động tốt hơn trên dữ liệu mới.

Báo cáo này không đặt mục tiêu đạt kết quả tốt nhất hiện nay. Báo cáo giải quyết một câu hỏi hẹp hơn: trên cùng một pipeline có kiểm soát, các mô hình CNN và Transformer trong danh sách bài đọc của môn học [1, 2, 3, 6, 7, 8] so với nhau ra sao trên dữ liệu trong miền và ngoài miền, và những thay đổi chi phí thấp có thu hẹp được khoảng cách giữa hai loại dữ liệu này không?

Báo cáo trả lời ba câu hỏi nghiên cứu:

- **RQ1.** Với khoảng 1.450 ảnh huấn luyện, các mô hình dựa trên Transformer (TransUNet, Swin-Unet) có vượt các mô hình CNN (MultiResUNet, CE-Net) một cách có ý nghĩa thống kê không?
- **RQ2.** Mô hình nào giữ hiệu năng tốt nhất trên các tập ngoài miền CVC-ColonDB, ETIS và CVC-300?
- **RQ3.** Hàm mất mát chú ý đường biên và augmentation theo màu sắc thu hẹp khoảng cách tổng quát hóa được bao nhiêu, và thành phần nào đóng góp chính?

Phần còn lại được tổ chức như sau. Mục 2 điểm lại các mạng CNN encoder–decoder, phân vùng dựa trên Transformer và các benchmark polyp. Mục 3 phát biểu bài toán và mô tả dữ liệu. Mục 4 trình bày pipeline thực nghiệm và các mô hình, tiếp theo là hàm mất mát và các cải tiến đề xuất ở Mục 5. Mục 6 và 7 trình bày thiết lập thực nghiệm và kết quả. Mục 8 nêu các giới hạn về độ tin cậy, và Mục 9 kết luận.

2 Các công trình liên quan

2.1 Mạng CNN encoder–decoder cho phân vùng ảnh y tế

U-Net kết hợp một encoder thu hẹp với một decoder mở rộng và chuyển đặc trưng độ phân giải cao qua các skip connection, nhờ đó học được từ ít ảnh có nhãn [1]. MultiResUNet thay hai lớp tích chập ở mỗi tầng bằng một khối MultiRes, gồm chuỗi

tích chập 3×3 có đầu ra được ghép lại để bao nhiều vùng tiếp nhận, và thêm các "Res path" có kết nối phần dư trên skip connection để giảm khoảng cách ngữ nghĩa giữa đặc trưng encoder và decoder; mô hình được đánh giá trên năm bộ dữ liệu y sinh, trong đó có CVC-ClinicDB và ISIC 2018 [6]. CE-Net đặt một khối tích chập giãn nở dày đặc (DAC) và một khối gộp đa nhân có phần dư (RMP) giữa encoder ResNet đã huấn luyện trước và decoder, để thu ngữ cảnh đa tỉ lệ mà không giảm thêm độ phân giải [7]. nnU-Net không đề xuất kiến trúc mới: khung này tự cấu hình tiền xử lý, cấu trúc mạng, huấn luyện và hậu xử lý từ "dấu vân tay" của bộ dữ liệu, và được đánh giá trên mười bài toán của Medical Segmentation Decathlon [8].

2.2 Transformer cho phân vùng ảnh y tế

Tích chập nắm bắt mẫu cục bộ, và vùng tiếp nhận hạn chế khiến khó mô hình hóa ngữ cảnh tầm xa. TransUNet đưa bản đồ đặc trưng CNN vào một encoder Vision Transformer rồi giải mã bằng bộ upsample nhiều tầng cùng skip connection kiểu U-Net [2]. Swin-Unet xây toàn bộ mạng hình chữ U từ các khối Swin Transformer, với cửa sổ dịch chuyển giúp giảm chi phí self-attention, và upsample bằng các lớp patch expanding [3]. Cả hai mô hình được đánh giá trên bộ CT đa cơ quan Synapse và bộ MRI tim ACDC, không phải trên ảnh nội soi đại tràng.

2.3 Benchmark phân vùng polyp và thực hành đánh giá

PraNet đưa ra giao thức mà phần lớn các công trình về polyp áp dụng: huấn luyện trên 900 ảnh Kvasir-SEG và 550 ảnh CVC-ClinicDB, kiểm tra trên năm bộ [4]. PolypGen bổ sung ảnh từ sáu trung tâm để kiểm tra khả năng tổng quát hóa [9]. Bài kiểm định trong [5] ghi nhận ít nhất năm giao thức chia dữ liệu không tương thích đang được dùng, lỗi chép số liệu trong các bảng tổng hợp, và chênh lệch HD95 tới khoảng 16 px giữa các thư viện tính độ đo. Bài này đề xuất một danh mục báo cáo: HD95 và recall là độ đo chính, nêu rõ giao thức chia dữ liệu, có tập kiểm tra bên ngoài, và kiểm định ý nghĩa trên điểm của từng ảnh. Metrics Reloaded đưa ra hướng dẫn chung về chọn độ đo cho bài toán phân vùng [10]. Báo cáo này làm theo các khuyến nghị đó.

3 Phát biểu bài toán và dữ liệu

3.1 Phát biểu bài toán

Mỗi ảnh $x \in \mathbb{R}^{H \times W \times 3}$ có một mặt nạ nhị phân $y \in \{0,1\}^{H \times W}$ đánh dấu các điểm ảnh thuộc polyp. Mô hình f_θ trả về một bản đồ xác suất, và mặt nạ dự đoán có được bằng cách lấy ngưỡng:

$$p = f_\theta(x) \in [0,1]^{H \times W}, \qquad \hat{y} = \mathbb{1}[\, p \geq 0{,}5 \,]. \tag{1}$$

Ảnh huấn luyện đến từ miền nguồn $\mathcal{D}_S$ (Kvasir-SEG và CVC-ClinicDB). Ảnh kiểm tra đến từ $\mathcal{D}_S$ và từ K miền đích $\mathcal{D}_T^1, \ldots, \mathcal{D}_T^K$ không bao giờ xuất hiện khi huấn luyện (CVC-ColonDB, ETIS và CVC-300). Với một điểm số theo ảnh s (Dice trong phân

Bảng 1: Các bộ dữ liệu và vai trò.

Bộ dữ liệu	Số ảnh	Độ phân giải	Vai trò
Kvasir-SEG [11]	1.000	khác nhau	Huấn luyện; kiểm tra trong miền
CVC-ClinicDB [12]	612	384×288	Huấn luyện; kiểm tra trong miền
CVC-ColonDB [13]	380	574×500	Kiểm tra ngoài miền
ETIS-LaribPolypDB [14]	196	1225×966	Kiểm tra ngoài miền
CVC-300 (EndoScene) [15]	60	[kiểm tra]	Kiểm tra ngoài miền

Bảng 2: Số ảnh của mỗi tập.

Tập	Kvasir	ClinicDB	ColonDB	ETIS	CVC-300	Tổng
Huấn luyện	810	495	–	–	–	1.305
Validation	90	55	–	–	–	145
Kiểm tra	100	62	380	196	60	798

tích chính), khoảng cách tổng quát hóa của một mô hình là

$$\Delta = \bar{s}\big(\mathcal{D}_S^{\text{test}}\big) - \frac{1}{K}\sum_{k=1}^{K} \bar{s}\big(\mathcal{D}_T^{k}\big), \tag{2}$$

trong đó $\bar{s}$ là điểm trung bình trên các ảnh của một tập. Mô hình tổng quát hóa tốt hơn khi đạt điểm cao trên các miền đích và có Δ nhỏ.

3.2 Nguồn dữ liệu

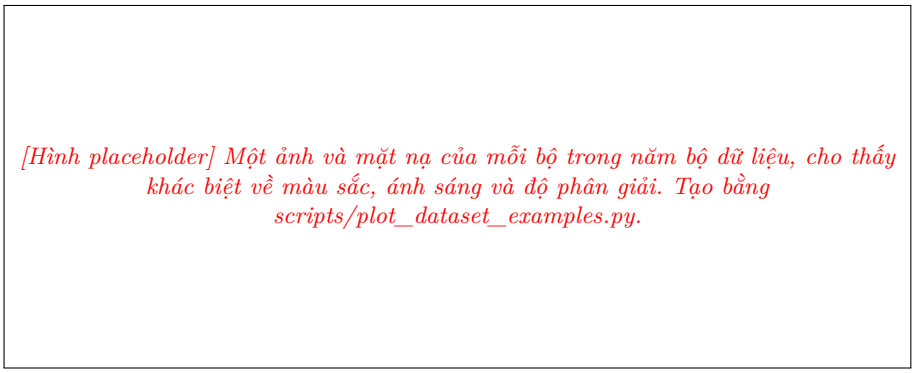
Bảng 1 liệt kê năm bộ dữ liệu công khai. Kvasir-SEG và CVC-ClinicDB cung cấp ảnh huấn luyện; CVC-ColonDB, ETIS và CVC-300 chỉ dùng để kiểm tra. Cả năm bộ được dùng theo dạng đã phát hành kèm PraNet [4].

3.3 Chia dữ liệu

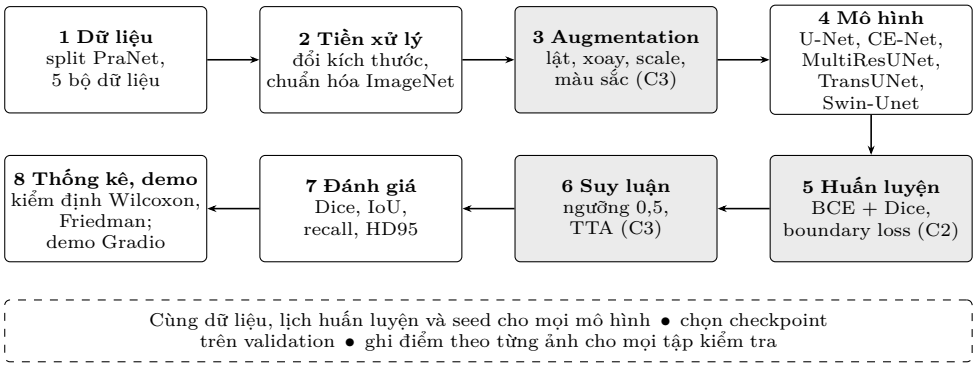
Bảng 2 cho số ảnh của mỗi tập. Ảnh huấn luyện và kiểm tra theo split cố định của PraNet [4]. Mười phần trăm ảnh huấn luyện của mỗi bộ nguồn được tách ngẫu nhiên (seed 42) làm tập validation, để chọn checkpoint mà không đụng đến tập kiểm tra nào. Vì ba bộ CVC do các nhóm có liên quan thu thập, các ảnh gần trùng giữa tập huấn luyện và tập kiểm tra được kiểm tra bằng perceptual hashing trước khi huấn luyện, như trong [5]. Hình 1 minh họa một số ảnh mẫu.

4 Pipeline thực nghiệm

Hình 2 trình bày pipeline, và Bảng 3 liệt kê các mô hình. Mọi mô hình đi qua cùng các tầng với cùng dữ liệu, augmentation, hàm mất mát và lịch huấn luyện; chỉ kiến



Hình 1: Ảnh mẫu và mặt nạ nhãn của từng bộ dữ liệu.



Hình 2: Pipeline thực nghiệm. Các tầng tô xám được thay đổi bởi các cải tiến đề xuất (C2: hàm mất mát chú ý đường biên; C3: augmentation theo miền và augmentation khi suy luận).

trúc thay đổi, nên chênh lệch kết quả có thể quy cho kiến trúc chứ không phải cho cách huấn luyện. Các tầng tô xám là nơi áp dụng các cải tiến ở Mục 5.

TransUNet và Swin-Unet mặc định nhận ảnh 224×224, còn các mô hình CNN theo PraNet dùng 352×352. Kích thước đầu vào của từng mô hình được ghi ở Phụ lục A, và dự đoán được đưa về độ phân giải gốc trước khi đánh giá, nên mọi mô hình được chấm trên cùng một mặt nạ. Mỗi lần chạy ghi cấu hình, seed và điểm theo từng ảnh vào một nhật ký chung. Mô hình tốt nhất được đưa vào một demo Gradio [16], hiển thị mặt nạ dự đoán chồng lên ảnh người dùng tải lên.

Bảng 3: Các mô hình được so sánh ("#" là số thứ tự trong danh sách bài đọc của môn học).

Mô hình	#	Ý tưởng chính	Vấn đề giải quyết	Ưu tiên
U-Net [1]	–	Encoder–decoder với skip connection	Mốc so sánh cơ bản	Bắt buộc
MultiResUNet [6]	59	Khối MultiRes; Res path	Polyp nhiều kích thước; khoảng cách ngữ nghĩa encoder–decoder	Bắt buộc
CE-Net [7]	60	Khối DAC và RMP ở bottleneck	Mất chi tiết không gian do pooling liên tục	Bắt buộc
TransUNet [2]	57	Đặc trưng CNN, encoder ViT, decoder U-Net	Vùng tiếp nhận hạn chế của CNN	Bắt buộc*
Swin-Unet [3]	56	Mạng chữ U gồm các khối Swin Transformer	Ngữ cảnh toàn cục với chi phí thấp hơn ViT	Tùy chọn*
nnU-Net [8]	58	Pipeline U-Net tự cấu hình	Mốc so sánh mạnh không cần chỉnh tay	Tùy chọn

*Cần làm ít nhất một trong hai mô hình Transformer.

5 Hàm mất mát và các cải tiến đề xuất

5.1 Hàm mất mát phân vùng

Mọi mô hình được huấn luyện với tổng của binary cross-entropy và soft Dice loss:

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{BCE}}(p, y) + 1 - \frac{2\sum_i p_i y_i + \epsilon}{\sum_i p_i + \sum_i y_i + \epsilon}, \tag{3}$$

trong đó i chạy trên các điểm ảnh và ϵ tránh chia cho 0. Cross-entropy cho gradient ở mọi điểm ảnh, còn thành phần Dice bù cho sự mất cân bằng giữa vùng polyp nhỏ và phần nền lớn.

5.2 Hàm mất mát chú ý đường biên (C2)

Dice và cross-entropy đếm điểm ảnh, nên một dự đoán phủ đúng polyp nhưng lệch biên vài điểm ảnh gần như không bị phạt, trong khi HD95 lại nhạy với lỗi này. Theo Kervadec và cộng sự [17], nhóm thêm một thành phần có trọng số là bản đồ khoảng cách có dấu ϕ_G tới đường biên của mặt nạ nhãn, âm bên trong polyp và dương bên ngoài:

$$\mathcal{L}_B = \frac{1}{|\Omega|} \sum_{q \in \Omega} \phi_G(q)\, p(q), \qquad \mathcal{L} = \mathcal{L}_{\text{seg}} + \lambda\, \mathcal{L}_B. \tag{4}$$

Bảng 4: Cấu hình thực nghiệm chính.

Thành phần	Cấu hình
Dữ liệu huấn luyện	1.305 ảnh (tập huấn luyện của split PraNet trừ 10% làm validation)
Kích thước đầu vào	352×352 cho CNN; 224×224 cho TransUNet và Swin-Unet [xác nhận]
Chuẩn hóa	Trung bình và độ lệch chuẩn của ImageNet
Augmentation	Lật, xoay, scale ngẫu nhiên, đổi màu nhẹ; bộ biến đổi quang học mạnh hơn cho C3
Bộ tối ưu	AdamW [21], learning rate 10^{-4}, weight decay [giá trị]
Batch, số epoch	8–16, 100 epoch, mixed precision
Hàm mất mát	BCE + Dice (công thức 3); thêm boundary loss cho C2 (công thức 4)
Chọn checkpoint	Dice cao nhất trên validation; không dùng tập kiểm tra để chọn
Framework, phần cứng	PyTorch [22] [phiên bản]; GPU Google Colab hoặc Kaggle [loại]
Seed	42 [thêm hai seed nếu đủ thời gian GPU]

Xác suất đặt ở xa bên ngoài vùng thật bị phạt nặng hơn xác suất gần biên. Theo khuyến nghị trong [17], λ bắt đầu nhỏ và tăng dần trong quá trình huấn luyện, tới [giá trị]. Nếu thành phần này làm huấn luyện mất ổn định, phương án dự phòng là thêm một nhánh phụ dự đoán bản đồ đường biên.

5.3 Augmentation theo miền và augmentation khi suy luận (C3)

Nhóm giả định rằng phần lớn khác biệt giữa các trung tâm đến từ màu sắc, ánh sáng và độ phân giải của máy nội soi. Vì vậy augmentation cơ bản (lật, xoay, scale, đổi độ sáng nhẹ) được mở rộng bằng các biến đổi quang học mạnh hơn: độ sáng và độ tương phản, dịch sắc độ và độ bão hòa, gamma, làm mờ và nén JPEG, cài đặt bằng Albumentations [18]. Khi suy luận, dự đoán được lấy trung bình qua phép lật ngang và lật dọc. Tác dụng được đo bằng thay đổi của khoảng cách Δ trong công thức (2).

5.4 Encoder huấn luyện trước mạnh hơn (C1, tùy chọn)

Nếu bảng so sánh baseline hoàn thành trước tuần 4, encoder của mô hình tốt nhất được thay bằng backbone PVTv2 [19] hoặc ConvNeXt [20] huấn luyện trước trên ImageNet, còn decoder giữ các Res path của MultiResUNet. Mục tiêu là kết hợp ngữ cảnh toàn cục với chi tiết đa tỉ lệ.

6 Thiết lập thực nghiệm

Bảng 4 tóm tắt cấu hình. Với mặt nạ dự đoán $\hat{y}$ và mặt nạ nhãn y, các độ đo chồng lấp và độ nhạy là

$$\mathrm{Dice} = \frac{2|\hat{y} \cap y|}{|\hat{y}| + |y|}, \qquad \mathrm{IoU} = \frac{|\hat{y} \cap y|}{|\hat{y} \cup y|}, \qquad \mathrm{Recall} = \frac{|\hat{y} \cap y|}{|y|}. \tag{5}$$

Recall được báo cáo vì bỏ sót polyp nguy hiểm hơn báo nhầm. Độ chính xác đường biên được đo bằng phân vị thứ 95 của khoảng cách Hausdorff đối xứng,

$$\mathrm{HD95}(\hat{y}, y) = \max\Big\{ P_{95}\big\{ d(a, \partial y) : a \in \partial \hat{y} \big\},\ P_{95}\big\{ d(b, \partial \hat{y}) : b \in \partial y \big\} \Big\}, \tag{6}$$

trong đó ∂ là đường biên của mặt nạ và d là khoảng cách Euclid tính bằng điểm ảnh ở độ phân giải gốc. Vì giá trị HD95 khác nhau giữa các thư viện [5], nhóm dùng một thư viện duy nhất ([tên, phiên bản]) cho mọi mô hình, và gán HD95 bằng đường chéo ảnh khi dự đoán rỗng. Mọi độ đo được tính theo từng ảnh rồi lấy trung bình trên mỗi tập kiểm tra (mDice, mIoU).

Hai mô hình được so sánh bằng kiểm định hạng có dấu Wilcoxon [23] trên cặp điểm Dice của từng ảnh; chênh lệch chỉ được coi là có ý nghĩa khi $p < 0{,}05$. Để so sánh mọi mô hình cùng lúc, nhóm dùng kiểm định Friedman [24] rồi kiểm định hậu nghiệm, theo khuyến nghị của Demšar [25]. Giá trị trung bình trên các tập ngoài miền được báo cáo kèm khoảng tin cậy bootstrap 95%. Hiệu quả tính toán được báo cáo bằng số tham số, FLOPs và số khung hình mỗi giây với batch bằng 1.

7 Kết quả và thảo luận

7.1 So sánh CNN và Transformer (RQ1)

[Placeholder] So sánh mDice của mọi mô hình trên năm tập kiểm tra (Bảng 5). Nêu rõ Transformer tốt nhất có tốt hơn CNN tốt nhất một cách có ý nghĩa thống kê không, và thảo luận vai trò của trọng số huấn luyện trước trên ImageNet.

7.2 Tổng quát hóa ngoài miền (RQ2)

[Placeholder] Báo cáo khoảng cách Δ, recall và HD95 trên các tập ngoài miền (Bảng 6). Chỉ ra mô hình giảm ít nhất và thứ hạng có thay đổi giữa Dice và HD95 hay không (Hình 3).

7.3 Ablation các cải tiến đề xuất (RQ3)

[Placeholder] Xuất phát từ baseline tốt nhất sau tuần 4, thêm từng thành phần và báo cáo tác dụng (Bảng 7). Cải tiến không có ý nghĩa thống kê vẫn được báo cáo như một kết quả âm.

Bảng 5: mDice trên năm tập kiểm tra. Số liệu của PraNet lấy từ [4], chỉ dùng để đối chiếu.

	Trong miền		Ngoài miền			
Mô hình	Kvasir	ClinicDB	ColonDB	ETIS	CVC-300	p so với CNN
PraNet [4]	0,898	0,899	0,709	0,628	0,871	–
U-Net	–	–	–	–	–	–
MultiResUNet	–	–	–	–	–	–
CE-Net	–	–	–	–	–	–
TransUNet	–	–	–	–	–	–
Swin-Unet	–	–	–	–	–	–

Bảng 6: Khả năng tổng quát hóa của từng mô hình. Trong miền: Kvasir và ClinicDB; ngoài miền: ColonDB, ETIS và CVC-300 (trung bình của ba tập, khoảng tin cậy 95% trong ngoặc).

Mô hình	mDice trong miền	mDice ngoài miền	Δ	Recall ngoài miền	HD95 ngoài miền (px)
U-Net	–	–	–	–	–
MultiResUNet	–	–	–	–	–
CE-Net	–	–	–	–	–
TransUNet	–	–	–	–	–
Swin-Unet	–	–	–	–	–

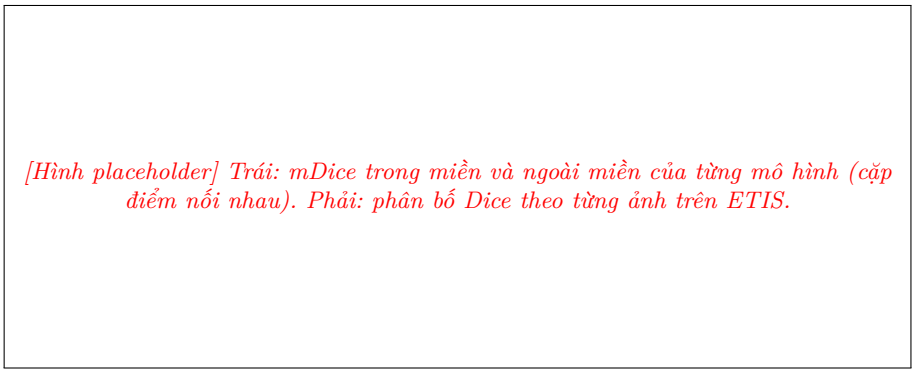
7.4 Phân tích lỗi và hiệu quả tính toán

[Placeholder] Hiển thị các ảnh có Dice thấp nhất của mỗi tập kiểm tra (Hình 4), chia kết quả theo kích thước polyp, và so sánh chi phí mô hình (Bảng 8).

8 Độ tin cậy và hạn chế

Bằng chứng của báo cáo bị giới hạn ở một số điểm. Các mô hình được huấn luyện trên 1.305 ảnh từ hai nguồn, còn các tập ngoài miền nhỏ (60–380 ảnh), nên giá trị trung bình có khoảng tin cậy rộng; chênh lệch nhỏ hơn khoảng này không được diễn giải. Mọi ảnh kiểm tra đều có ít nhất một polyp, nên báo động nhầm trên khung hình bình thường không được đo, và ảnh tĩnh do nhóm tạo bộ dữ liệu chọn lọc sạch hơn video thực tế, vốn có nhòe, phản chiếu ánh sáng và chuyển động.

Thời gian GPU miễn phí giới hạn số lần chạy, nên một số cấu hình chỉ được huấn luyện với một seed. Siêu tham số được dùng chung chứ không tinh chỉnh riêng cho từng mô hình, điều này có thể có lợi cho mô hình có công thức huấn luyện gốc gần với công thức chung. Các mô hình tái hiện được huấn luyện trên dữ liệu và kích thước đầu vào khác với bài báo gốc, nên điểm số chỉ được so sánh trong pipeline này và với PraNet, không so trực tiếp với số liệu của bài gốc. Đây là một so sánh học thuật trên



Hình 3: Khoảng cách tổng quát hóa của từng mô hình.

Bảng 7: Ablation trên mô hình baseline tốt nhất. Giá trị p so sánh từng dòng với baseline trên Dice ngoài miền theo từng ảnh.

Cấu hình	mDice trong miền	mDice ngoài miền	Δ	HD95 ngoài miền (px)	p
Baseline tốt nhất [tên]	–	–	–	–	–
+ C3 (augmentation miền + TTA)	–	–	–	–	–
+ C2 (boundary loss)	–	–	–	–	–
+ C2 + C3	–	–	–	–	–
C1 + C2 + C3 (tùy chọn)	–	–	–	–	–

dữ liệu công khai; nghiên cứu không có kiểm chứng lâm sàng, và demo không phải là thiết bị y tế.

9 Kết luận và hướng phát triển

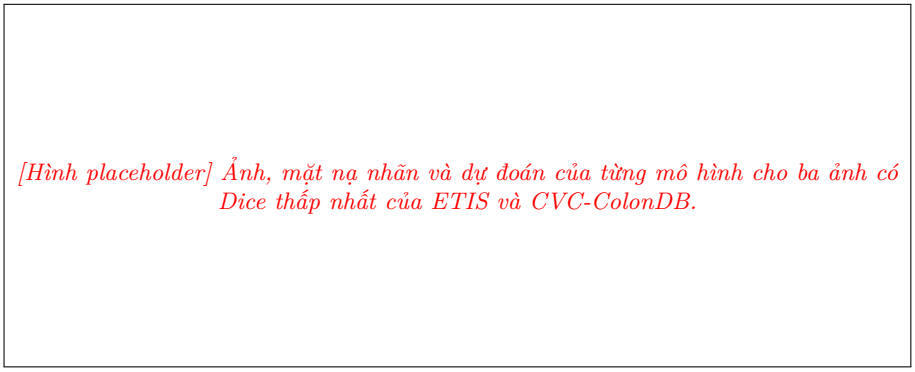
[Placeholder] Tóm tắt câu trả lời cho RQ1–RQ3 trong một đoạn, kèm các số liệu chính.

Hướng phát triển gần nhất là kiểm tra các mô hình trên PolypGen [9], với sáu trung tâm cho đánh giá bên ngoài chặt chẽ hơn các tập benchmark công khai. Đánh giá trên video nội soi sẽ đo được độ ổn định giữa các khung hình và báo động nhầm trên khung hình không có polyp. Mô hình nhẹ hơn cho suy luận thời gian thực, và huấn luyện bán giám sát với khung hình nội soi chưa gán nhãn, là các hướng mở rộng tiếp theo.

Dữ liệu và mã nguồn. Mã nguồn, cấu hình, danh sách chia dữ liệu, điểm theo từng ảnh và script vẽ hình được lưu trong kho mã của đề tài [URL]. Các bộ dữ liệu là dữ liệu công khai, tuân theo điều khoản gốc của từng bộ, và không được phát hành lại.

Bảng 8: Kích thước mô hình và tốc độ suy luận (batch bằng 1, [GPU]).

Mô hình	Số tham số (triệu)	FLOPs (G)	Khung hình/giây
U-Net	–	–	–
MultiResUNet	–	–	–
CE-Net	–	–	–
TransUNet	–	–	–
Swin-Unet	–	–	–
Mô hình đề xuất	–	–	–



Hình 4: Các trường hợp lỗi điển hình trên ảnh ngoài miền.

Phụ lục A Thiết lập riêng của từng mô hình

Bảng A1: Các thiết lập khác nhau giữa các mô hình (IN: ImageNet). Các thiết lập còn lại theo Bảng 4.

Mô hình	Kích thước đầu vào	Trọng số huấn luyện trước	Batch	Epoch	Số tham số (triệu)
U-Net	352×352	không	–	–	–
MultiResUNet	352×352	không	–	–	–
CE-Net	352×352	ResNet-34 (IN-1k)	–	–	–
TransUNet	224×224	R50-ViT-B/16 (IN-21k)	–	–	–
Swin-Unet	224×224	Swin-T (IN-1k)	–	–	–
Mô hình đề xuất	–	–	–	–	–

Phụ lục B Bản đồ tài nguyên tái lập

Bảng B2: Các tài nguyên chính trong kho mã của đề tài (bố cục dự kiến; cập nhật theo đường dẫn cuối cùng).

Mục đích	Tài nguyên
Hướng dẫn chạy	README.md
Danh sách chia dữ liệu	data/splits/{train,val,test}_*.txt
Kiểm tra ảnh trùng	scripts/check_duplicates.py
Cấu hình thí nghiệm	configs/*.yaml
Mã các mô hình	src/models/
Hàm mất mát	src/losses.py
Huấn luyện và đánh giá	scripts/train.py, scripts/evaluate.py
Điểm theo từng ảnh	outputs/metrics/per_image_*.csv
Kiểm định thống kê	scripts/stats_tests.py
Hình trong báo cáo	scripts/plot_report_figures.py → report/figures/
Demo	app/gradio_app.py

Tài liệu tham khảo

[1] Ronneberger, O., Fischer, P., Brox, T.: U-Net: Convolutional Networks for Biomedical Image Segmentation. In: Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. LNCS, vol. 9351, pp. 234–241. Springer (2015)

[2] Chen, J., Lu, Y., Yu, Q., et al.: TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation. arXiv preprint arXiv:2102.04306 (2021)

[3] Cao, H., Wang, Y., Chen, J., et al.: Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation. In: Computer Vision – ECCV 2022 Workshops (2023). arXiv:2105.05537

[4] Fan, D.-P., Ji, G.-P., Zhou, T., Chen, G., Fu, H., Shen, J., Shao, L.: PraNet: Parallel Reverse Attention Network for Polyp Segmentation. In: Medical Image Computing and Computer-Assisted Intervention – MICCAI 2020 (2020). arXiv:2006.11392. Code and data split: https://github.com/DengPingFan/PraNet

[5] Urooj, A., Abdien, Z.U., Madan, N.: Metrics or Mirage? An Audit of Evaluation Inconsistencies in Colonoscopy Polyp Segmentation Benchmarks. arXiv preprint arXiv:2607.08203 (2026)

[6] Ibtehaz, N., Rahman, M.S.: MultiResUNet: Rethinking the U-Net Architecture for Multimodal Biomedical Image Segmentation. Neural Networks 121, 74–87 (2020)

[7] Gu, Z., Cheng, J., Fu, H., et al.: CE-Net: Context Encoder Network for 2D Medical Image Segmentation. IEEE Transactions on Medical Imaging 38(10), 2281–2292 (2019)

[8] Isensee, F., Petersen, J., Klein, A., et al.: nnU-Net: Self-adapting Framework for U-Net-Based Medical Image Segmentation. arXiv preprint arXiv:1809.10486 (2018). Extended version: Nature Methods 18, 203–211 (2021)

[9] Ali, S., Jha, D., Ghatwary, N., et al.: A Multi-centre Polyp Detection and Segmentation Dataset for Generalisability Assessment. Scientific Data 10, 75 (2023)

[10] Maier-Hein, L., Reinke, A., Godau, P., et al.: Metrics Reloaded: Recommendations for Image Analysis Validation. Nature Methods 21(2), 195–212 (2024)

[11] Jha, D., Smedsrud, P.H., Riegler, M.A., Halvorsen, P., de Lange, T., Johansen, D., Johansen, H.D.: Kvasir-SEG: A Segmented Polyp Dataset. In: MultiMedia Modeling (MMM 2020). LNCS, vol. 11962, pp. 451–462. Springer (2020)

[12] Bernal, J., Sánchez, F.J., Fernández-Esparrach, G., Gil, D., Rodríguez, C., Vilariño, F.: WM-DOVA Maps for Accurate Polyp Highlighting in Colonoscopy:

Validation vs. Saliency Maps from Physicians. Computerized Medical Imaging and Graphics 43, 99–111 (2015)

[13] Bernal, J., Sánchez, J., Vilariño, F.: Towards Automatic Polyp Detection with a Polyp Appearance Model. Pattern Recognition 45(9), 3166–3182 (2012)

[14] Silva, J., Histace, A., Romain, O., Dray, X., Granado, B.: Toward Embedded Detection of Polyps in WCE Images for Early Diagnosis of Colorectal Cancer. International Journal of Computer Assisted Radiology and Surgery 9(2), 283–293 (2014)

[15] Vázquez, D., Bernal, J., Sánchez, F.J., et al.: A Benchmark for Endoluminal Scene Segmentation of Colonoscopy Images. Journal of Healthcare Engineering 2017, 4037190 (2017)

[16] Abid, A., Abdalla, A., Abid, A., Khan, D., Alfozan, A., Zou, J.: Gradio: Hassle-Free Sharing and Testing of ML Models in the Wild. arXiv preprint arXiv:1906.02569 (2019)

[17] Kervadec, H., Bouchtiba, J., Desrosiers, C., Granger, E., Dolz, J., Ben Ayed, I.: Boundary Loss for Highly Unbalanced Segmentation. Medical Image Analysis 67, 101851 (2021)

[18] Buslaev, A., Iglovikov, V.I., Khvedchenya, E., Parinov, A., Druzhinin, M., Kalinin, A.A.: Albumentations: Fast and Flexible Image Augmentations. Information 11(2), 125 (2020)

[19] Wang, W., Xie, E., Li, X., et al.: PVT v2: Improved Baselines with Pyramid Vision Transformer. Computational Visual Media 8(3), 415–424 (2022)

[20] Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., Xie, S.: A ConvNet for the 2020s. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 11976–11986 (2022)

[21] Loshchilov, I., Hutter, F.: Decoupled Weight Decay Regularization. In: International Conference on Learning Representations (ICLR) (2019)

[22] Paszke, A., Gross, S., Massa, F., et al.: PyTorch: An Imperative Style, High-Performance Deep Learning Library. In: Advances in Neural Information Processing Systems 32 (2019)

[23] Wilcoxon, F.: Individual Comparisons by Ranking Methods. Biometrics Bulletin 1(6), 80–83 (1945)

[24] Friedman, M.: The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance. Journal of the American Statistical Association 32(200), 675–701 (1937)

[25] Demšar, J.: Statistical Comparisons of Classifiers over Multiple Data Sets. Journal of Machine Learning Research 7, 1–30 (2006)